강판 결함 데이터 탐색적 분석(EDA) 결과

1. 분석 개요

항목	내용
데이터	Steel Plates Faults (UCI Machine Learning Repository)
원본 크기	1,941행 × 34열 (입력 변수 27개, 결함 유형 표시 열 7개)
분석 단위	1행 = 강판 결함 관측 1건 (강판 1개 단위가 아님)
목표 변수	7개 결함 유형 표시 열을 합친 단일 라벨 fault_type (7개 클래스 다중 분류)
분석 단계	1단계 데이터 구조 → 2단계 데이터 품질 → 3단계 종속변수 분포 → 4단계 독립변수 분포 → 5단계 결함 유형별 특성 비교 → 6단계 독립변수 간 관계

2. 1단계: 데이터 구조 및 변수 유형

2.1 데이터 구조

항목	결과	의미
크기	1,941행 × 34열	원본 규모와 일치함
데이터 타입	int64 21개, float64 13개, 문자형(object) 0개	모든 열이 숫자로 정상 인식되어 타입 변환이 불필요함
정렬 상태	앞 5행은 모두 Pastry, 뒤 5행은 모두 Other_Faults	데이터가 결함 유형별로 정렬되어 있어, 분할 시 섞어야 함
숫자 범위	Y_Minimum 최댓값 약 1,299만, 지표 변수는 0~1	변수 간 숫자 범위 차이가 매우 큼
평균과 중앙값	Pixels_Areas 평균 1,894, 중앙값 174	소수의 큰 값이 평균을 끌어올린 치우친 분포임

2.2 변수 유형 분류

구분	변수 묶음	변수	개수
수치형 (입력)	위치	X_Minimum, X_Maximum, Y_Minimum, Y_Maximum, Edges_Index	5
수치형 (입력)	크기	Pixels_Areas, X_Perimeter, Y_Perimeter, Outside_X_Index	4
수치형 (입력)	면적·축 변환값	LogOfAreas, Log_X_Index, Log_Y_Index, SigmoidOfAreas	4
수치형 (입력)	밝기	Sum_of_Luminosity, Minimum_of_Luminosity, Maximum_of_Luminosity, Luminosity_Index	4
수치형 (입력)	형상	Empty_Index, Square_Index, Edges_X_Index, Edges_Y_Index, Outside_Global_Index, Orientation_Index	6
수치형 (입력)	강판·공정	Steel_Plate_Thickness, Length_of_Conveyer	2
범주형 (입력)	강종	TypeOfSteel_A300, TypeOfSteel_A400	2
범주형 (정답)	결함 유형	Pastry, Z_Scratch, K_Scatch, Stains, Dirtiness, Bumps, Other_Faults	7

- 분류 기준: 모든 열이 숫자형이라 데이터 타입으로는 구분할 수 없으므로, 변수의 의미와 고유값 개수(nunique)를 기준으로 분류함.
- Outside_Global_Index(고유값 3개)와 Steel_Plate_Thickness(고유값 24개)는 값의 종류가 적지만 크기에 의미가 있어 수치형으로 분류함.

2.3 지표 변수의 의미 (0번 행 값으로 계산식 검증)

0번 행의 가로 폭은 8(X_Maximum 50 − X_Minimum 42), 세로 길이는 44(Y_Maximum 270,944 − Y_Minimum 270,900), 면적은 267, Length_of_Conveyer는 1,687임.

변수	계산식	0번 행 검증	의미
Edges_Index	2 × (가장 가까운 가장자리까지 거리) ÷ Length_of_Conveyer	2 × 42 ÷ 1,687 = 0.0498	0 = 가장자리, 1 = 정중앙
Empty_Index	1 − 면적 ÷ (가로 폭 × 세로 길이)	1 − 267 ÷ 352 = 0.2415	결함을 둘러싼 네모 상자 중 빈 부분의 비율
Square_Index	짧은 변 ÷ 긴 변	8 ÷ 44 = 0.1818	1 = 정사각형, 0에 가까울수록 길쭉함
Outside_X_Index	가로 폭 ÷ Length_of_Conveyer	8 ÷ 1,687 = 0.0047	가로 전체 길이 대비 결함 가로 폭
Edges_X_Index	가로 폭 ÷ X_Perimeter	8 ÷ 17 = 0.4706	1에 가까울수록 가로 테두리가 단순함
Edges_Y_Index	세로 길이 ÷ Y_Perimeter	44 ÷ 44 = 1.0	1에 가까울수록 세로 테두리가 단순함
Orientation_Index	세로가 길면 1 − 가로/세로, 가로가 길면 세로/가로 − 1	1 − 8/44 = 0.8182	양수 = 세로로 김, 음수 = 가로로 김, 절댓값 = 길쭉한 정도
Outside_Global_Index	세로가 길면 1, 가로가 길면 0, 같으면 0.5	1.0	결함이 길게 놓인 방향
LogOfAreas	log10(면적)	log10(267) = 2.4265	면적의 로그 변환값
Log_X_Index	log10(가로 폭)	log10(8) = 0.9031	가로 폭의 로그 변환값
Log_Y_Index	log10(세로 길이)	log10(44) = 1.6435	세로 길이의 로그 변환값
Luminosity_Index	(밝기 합계 ÷ 면적 − 128) ÷ 128	(90.71 − 128) ÷ 128 = −0.2913	평균 밝기 (0보다 작을수록 어두움)
SigmoidOfAreas	면적의 시그모이드 변환	−	면적을 0~1 범위로 누른 값

2.4 특이사항

- 강종 2개 열은 원핫 인코딩 형태로, 두 열이 서로 정반대 값을 가짐.
- 결함 유형이 0/1 열 7개로 나뉘어 있어 단일 라벨(fault_type) 변환이 필요함.
- 원본에 다른 변수를 변환해 만든 변수(LogOfAreas, Log_X_Index, Log_Y_Index, SigmoidOfAreas, Luminosity_Index 등)가 함께 포함되어 있음.
- K_Scatch는 원본 열 이름 표기를 그대로 사용함.

3. 2단계: 데이터 품질

항목	확인 방법	결과	의미
결측치	변수별 결측 개수·비율	34개 변수 모두 0건(0%), −999 등 결측 대체값 없음	결측 처리가 불필요함
중복	전체 34열 기준, 입력 27열 기준	각각 0건	측정값이 같은데 정답이 다른 모순 행이 없음
값의 범위	변수별 최솟값·최댓값	면적·둘레·두께는 0보다 큼, 밝기 0~253, 지표 0~1(방향 지표 −1~1)	범위를 벗어난 값이 없음
논리 오류	최솟값 > 최댓값인 행 (X, Y, 밝기)	모두 0건	한 행 안에서 모순된 값이 없음
강종 구성	두 열의 값 조합별 건수	A400 1,164건, A300 777건, 다른 조합 없음	모든 행이 강종을 정확히 하나 가짐
정답 구성	0/1 여부, 행별 합계	7개 열 모두 0/1, 1,941행 모두 합계 1	행마다 결함 유형이 정확히 하나여서 fault_type 생성이 가능함

- 비정상값(있을 수 없는 값)은 없으나, 다른 값보다 매우 큰 극단값은 존재함(4단계 참조).

4. 3단계: 종속변수(fault_type) 분포

결함 유형	건수	비율
Other_Faults	673	34.67%
Bumps	402	20.71%
K_Scatch	391	20.14%
Z_Scratch	190	9.79%
Pastry	158	8.14%
Stains	72	3.71%
Dirtiness	55	2.83%

- 7개 열 중 값이 1인 열의 이름으로 fault_type을 생성함. 원본 7개 열은 유지되어 분석용 데이터는 35열이 되었으며, 원본 크기는 34열 기준으로 기록함.

- 다수 클래스는 Other_Faults(673건), 소수 클래스는 Dirtiness(55건)이며, 건수 차이는 618건, 불균형 비율은 12.24배임.
- 7개 유형이 균등하다고 가정한 건수(약 277건)와 비교해도 유형 간 차이가 큼.
- 의미
- Accuracy만으로 평가하면 다수 유형 위주의 결과가 나올 수 있어 Macro F1을 주지표로 사용해야 함.
- Test 데이터를 20%로 나누면 Dirtiness는 약 11건, Stains는 약 14건만 남아, 한두 건 차이로 성능 수치가 크게 변할 수 있음.

5. 4단계: 독립변수 분포

5.1 위치

- X 좌표: X_Maximum이 192 이하인 결함이 약 485건(25%)으로, 가로 폭(약 1,700)의 약 11%인 X 0~192 구간에 전체의 4분의 1이 몰려 있음. 히스토그램에서도 X_Minimum은 0 근처(약 490건), X_Maximum은 200 근처(약 360건)에 막대가 집중됨.
- Edges_Index: 약 485건(25%)이 0.06 이하로 가장자리에 붙은 결함이 많음.
- Y 좌표: 절반(약 970건)이 약 120만 이하, 4분의 3(약 1,456건)이 약 218만 이하이며 최댓값은 약 1,299만으로, Y 값이 작은 앞쪽 위치에 결함이 집중되고 오른쪽으로 치우친 분포임.
- Y_Minimum과 Y_Maximum의 분포는 거의 동일함. 결함 하나의 세로 길이(예: 0번 행 44)가 위치 값(수백만 단위)에 비해 매우 작기 때문임.
- 의미: 가로 방향 한쪽 가장자리에 결함이 몰린 무리가 존재하며, 5단계에서 주로 K_Scatch임을 확인함.

5.2 크기

변수	중앙값(50%)	75% 지점	최댓값
Pixels_Areas	174	822	152,655
X_Perimeter	26	84	10,449
Y_Perimeter	25	83	18,152
Outside_X_Index	0.010	0.024	0.876

- 1,941건 중 약 1,456건(75%)이 면적 822 이하, 둘레 약 84 이하로 대부분 작고 좁은 결함임.
- 반면 최댓값은 중앙값의 수백 배로, 소수의 매우 큰 결함이 존재함. 이 때문에 평균 면적(1,894)이 중앙값(174)보다 훨씬 큼.

5.3 형상

변수	분포 (전체 1,941건 기준)

Empty_Index	0.4 부근을 중심으로 한 좌우 대칭에 가까운 분포, 가운데 절반(약 970건)이 0.32~0.50
Square_Index	0~1에 넓게 분포. 약 485건은 0.36 이하(길쭉함), 약 485건은 0.82 이상(정사각형에 가까움)
Edges_X_Index	약 1,456건(75%)이 0.41 이상이며, 1인 결함이 약 145건으로 가장 많음
Edges_Y_Index	절반(약 970건)이 0.95 이상으로 상한인 1에 몰려, 작은 값 쪽으로 꼬리가 있는 분포
Outside_Global_Index	값이 0, 0.5, 1 세 개뿐. 세로로 긴 결함 약 1,070건, 가로로 긴 결함 약 770건, 가로·세로가 같은 결함 약 90건
Orientation_Index	−1~1에 넓게 분포하며, 양수(세로로 김)가 조금 더 많음

- 형상 지표는 범위가 정해진 비율 값이라 멀리 떨어진 값이 생기기 어려워, 극단값이 거의 없음.
- 길쭉한 결함부터 정사각형에 가까운 결함까지 모양이 다양함.

5.4 밝기

- Minimum_of_Luminosity: 약 20~60과 약 80~120 두 곳에 봉우리가 있는 분포이며, 약 485건(25%)이 63 이하인 어두운 결함 무리가 따로 존재함(5단계에서 주로 K_Scatch임을 확인).
- Maximum_of_Luminosity: 가운데 절반(약 970건)이 124~140에 몰려, 전체 범위(37~253)에 비해 결함 간 차이가 작음.
- Sum_of_Luminosity: 약 1,456건(75%)이 83,011 이하인데 최댓값은 약 1,159만으로 크게 치우침. 밝기 합계는 평균 밝기에 면적을 곱한 값(0번 행: 24,220 ÷ 267 ≈ 91)이라 면적 분포를 그대로 따름.

5.5 강판 특성

- 강종: A400 1,164건(60.0%), A300 777건(40.0%)으로 A400이 약 1.5배 많으나, 결함 유형만큼 심하게 치우치지는 않음.
- 두께: 값이 40, 70, 100, 200, 300 등 정해진 24개 규격에만 존재함. 가장 얇은 40이 710건(36.6%)으로 가장 많고, 절반이 70 이하, 4분의 3이 80 이하임. 200~300의 두꺼운 강판은 소수로, 오른쪽으로 치우친 분포임.

5.6 치우침과 극단값

구분	변수 (왜도 / 극단값 건수, 비율)
크게 치우침 (왜도 5 이상)	Y_Perimeter (39.29 / 179건, 9.22%), X_Perimeter (21.54 / 352건, 18.13%), Pixels_Areas (14.08 / 395건, 20.35%), Sum_of_Luminosity (7.73 / 399건, 20.56%), Outside_X_Index (5.18 / 370건, 19.06%)
다소 치우침 (왜도 1~5)	Y_Minimum·Y_Maximum (2.81 / 각 81건, 4.17%), Steel_Plate_Thickness (2.21 / 240건, 12.36%), Maximum_of_Luminosity (1.29 / 146건, 7.52%), Log_X_Index (1.00 / 34건, 1.75%)
거의 대칭 (절댓값 1 미만)	나머지 15개. 형상 지표는 Empty_Index(20건, 1.03%)를 제외하고 극단값 0건이며, Edges_Y_Index만 반대 방향으로 약간 치우침(−0.93)

- 기준
- 왜도: 분포가 한쪽으로 치우친 정도. 0이면 좌우 대칭, 양수로 클수록 큰 값 쪽으로 꼬리가 길며, 절댓값 1 이상이면 많이 치우친 것으로 봄.
- 극단값: IQR 규칙(Q1 − 1.5×IQR 미만 또는 Q3 + 1.5×IQR 초과)으로 계산하며, 박스플롯에서 상자 밖에 찍히는 점과 같은 기준임.

- 왜도가 크게 치우친 변수는 모두 결함 크기와 관련된 변수임.
- Luminosity_Index는 왜도가 작으나(0.68) 극단값이 134건(6.90%)으로 많음. 가운데 절반이 좁게 몰려 있어 조금만 벗어나도 극단값으로 분류되기 때문임.
- 로그 변환 효과: Pixels_Areas를 로그 변환한 LogOfAreas는 왜도가 14.08에서 0.75로, 극단값이 395건에서 6건으로 줄어듦. 로그 변환은 큰 값을 크게, 작은 값을 작게 눌러 치우침을 줄임.
- 판단: 극단값은 비정상값이 아닌 실제 큰 결함이며, 비율이 최대 약 20%로 '큰 결함 무리'에 해당하므로 제거하지 않고 유지함. 5단계에서 면적 극단값의 상당수가 K_Scatch, 두꺼운 두께의 상당수가 Other_Faults임을 확인하여 이 판단을 뒷받침함. 두께 극단값(140 초과)은 200~300 등 두꺼운 제품 규격으로 오류가 아님.

6. 5단계: 결함 유형별 특성 비교

6.1 유형별 중앙값

유형	Pixels_Areas	Minimum_of_Luminosity	Maximum_of_Luminosity	Luminosity_Index	Empty_Index	Square_Index	Edges_X_Index	Edges_Y_Index	Orientation_Index
Other_Faults	146.0	97	127	−0.12	0.42	0.53	0.65	0.94	0.18
Bumps	120.5	91	127	−0.14	0.33	0.75	0.72	1.00	0.10
K_Scatch	6,281.0	41	134	−0.16	0.46	0.46	0.62	0.47	−0.52
Z_Scratch	146.0	93	124	−0.16	0.46	0.58	0.50	0.93	0.35
Pastry	209.0	80	126	−0.18	0.32	0.33	0.50	1.00	0.67
Stains	16.5	115	140	−0.00	0.41	0.70	1.00	1.00	−0.27
Dirtiness	145.0	107	132	−0.09	0.40	0.19	0.29	1.00	0.80

- 치우친 변수가 많아 평균 대신 중앙값으로 비교함. 중앙값은 대표값만 나타내므로, 실제 구분 가능성은 박스플롯의 겹침 정도와 함께 판단함.
- 유형 간 차이가 큰 변수: 면적, 최소 밝기, Square_Index, Edges_X_Index, Edges_Y_Index, Orientation_Index.
- 유형 간 차이가 작은 변수: 최대 밝기(124~140), Luminosity_Index(−0.18~0.00, Stains 제외 시 더 작음), Empty_Index(0.32~0.46).

6.2 면적 (LogOfAreas 박스플롯)

- 면적은 크게 치우쳐 원래 값으로는 비교가 어려워 로그 변환값(LogOfAreas)으로 비교함(2 = 면적 100, 3 = 1,000, 4 = 10,000).
- K_Scatch는 면적 중앙값 6,281로 다른 유형(120.5~209)보다 30배 이상 크며, 가운데 절반이 약 4,000~11,000에 있어 다른 유형의 상자(약 450 이하)와 겹치지 않음. 면적만으로도 구분이 쉬움.
- Stains는 중앙값 16.5로 가장 작고, 상자가 매우 좁아 크기가 일정함.
- 나머지 5개 유형(Other_Faults, Bumps, Z_Scratch, Pastry, Dirtiness)은 중앙값이 비슷하고 상자가 많이 겹쳐, 면적만으로는 구분이 어려움.

6.3 밝기

- 최소 밝기: K_Scatch의 상자(약 34~50)가 다른 유형(약 63 이상)과 겹치지 않을 만큼 어두움. 4단계 최소 밝기 분포의 어두운 봉우리가 K_Scatch에 해당함. 단, 밝은 쪽 극단값(약 90~195)도 존재하여 '대부분'으로 해석해야 함.
- Stains는 최소 밝기(115), 최대 밝기(140), 평균 밝기 지표(0.00) 모두 가장 높고 상자가 좁아, 밝기가 일정한 밝은 결함임. 평균 밝기 지표로는 다른 유형과 거의 겹치지 않음.
- 최대 밝기는 모든 유형의 상자가 110~145에서 겹쳐 단독으로는 구분력이 낮음.
- Other_Faults, Bumps, Z_Scratch는 밝기에서도 서로 겹치며, Other_Faults는 세 밝기 변수 모두에서 범위가 가장 넓고 극단값이 가장 많음.

6.4 형상

변수	유형별 차이 (중앙값)	의미
Square_Index	Dirtiness 0.19 ~ Bumps 0.75	Dirtiness·Pastry는 길쭉하고, Bumps·Stains는 정사각형에 가까움
Orientation_Index	K_Scatch −0.52 ~ Dirtiness 0.80	Dirtiness(0.80)·Pastry(0.67)는 세로로 길고, K_Scatch·Stains(−0.27)는 가로로 김
Edges_X_Index	Dirtiness 0.29 ~ Stains 1.00	Stains는 가로 테두리가 단순하고, Dirtiness는 복잡함
Edges_Y_Index	K_Scatch 0.47, 나머지 0.93~1.00	K_Scatch만 상자가 다른 유형과 겹치지 않을 만큼 낮음
Empty_Index	0.32~0.46	유형 간 차이가 작음

- Outside_Global_Index는 값이 3개뿐이라 박스플롯에서 제외함(같은 방향 정보를 Orientation_Index가 더 자세히 담고 있음).
- 면적으로 구분되지 않던 Dirtiness와 Pastry는 세로로 길쭉한 모양으로 구분됨. 두 유형은 모양이 비슷하지만 최소 밝기(107 vs 80)와 Edges_X_Index(0.29 vs 0.50)에서 차이를 보임.
- Other_Faults, Bumps, Z_Scratch는 대부분의 형상 지표에서 상자가 넓게 겹침.
- 4단계에서 세운 "긁힌 자국 계열은 길쭉할 것"이라는 가설은 부분적으로만 맞음. K_Scatch는 가로로 길쭉하지만, Z_Scratch는 중간 정도이며 가장 길쭉한 유형은 Dirtiness와 Pastry임.

6.5 위치 (가장자리 결함의 유형 확인)

- K_Scatch는 X_Minimum 상자가 약 20~55(중앙값 약 40), Edges_Index가 약 0.06으로 대부분 판 가장자리에서 시작함.
- 4단계에서 X_Minimum은 0 근처, X_Maximum은 200 근처에 몰린 패턴은, K_Scatch가 가장자리에서 시작해 가로로 길게 뻗은 큰 결함이기 때문으로 판단됨.
- Z_Scratch도 가장자리 근처(X_Minimum 중앙값 약 100, Edges_Index 약 0.15)에 많음.
- Stains는 Edges_Index 중앙값이 약 0.59로 판 안쪽에서 주로 발생함.
- 나머지 유형(Other_Faults, Bumps, Pastry, Dirtiness)은 가로 전체에 넓게 분포함. Dirtiness는 55건으로 퍼짐이 커 해석에 유의해야 함.

6.6 강종별 결함 유형 분포

강종	Other_Faults	Bumps	K_Scatch	Z_Scratch	Pastry	Stains	Dirtiness	합계
A300	266 (34.2%)	279 (35.9%)	1 (0.1%)	172 (22.1%)	49 (6.3%)	1 (0.1%)	9 (1.2%)	777
A400	407 (35.0%)	123 (10.6%)	390 (33.5%)	18 (1.5%)	109 (9.4%)	71 (6.1%)	46 (4.0%)	1,164

- K_Scatch(391건 중 390건)와 Stains(72건 중 71건)는 거의 A400에서만 발생했고, Dirtiness도 약 84%(55건 중 46건)가 A400임.
- Z_Scratch는 약 91%(190건 중 172건), Bumps는 약 69%(402건 중 279건)가 A300에서 발생하여, A300 결함의 92%가 Other_Faults·Bumps·Z_Scratch로 구성됨.
- Other_Faults는 두 강종 안에서의 비율이 34.2%, 35.0%로 비슷해 강종과 관계가 거의 없음.

6.7 두께별 결함 유형 분포 및 구간 검증

(1). 원래 구간 (40 / 41~70 / 71~100 / 101~300)

두께 구간	합계	주요 유형 (구간 안 비율)
40	710	K_Scatch 387건 (54.5%), Other_Faults 191건 (26.9%)
41~70	621	Other_Faults 171건 (27.5%), Z_Scratch 170건 (27.4%), Bumps 156건 (25.1%), Stains 71건 (11.4%)
71~100	331	Bumps 133건 (40.2%), Other_Faults 123건 (37.2%), Pastry 44건 (13.3%), Dirtiness 27건 (8.2%)
101~300	279	Other_Faults 188건 (67.4%), Pastry 39건 (14.0%), Bumps 35건 (12.5%)

- K_Scatch는 391건 중 387건(99%)이 가장 얇은 두께 40에서 발생함.
- Z_Scratch(190건 중 170건)와 Stains(72건 중 71건)는 대부분 41~70 구간에서 발생했고, Bumps는 약 72%(402건 중 289건)가 41~100 구간에 몰려 있음.
- Other_Faults는 두께가 두꺼울수록 비율이 높아짐(26.9% → 27.5% → 37.2% → 67.4%).

(2). 구간 변경 검증 (40 / 41~60 / 61~80 / 81~150 / 151~300)

확인 항목	원래 구간	변경 구간	결과
K_Scatch는 두께 40에 집중	40에 387건 (54.5%)	40에 387건 (54.5%)	유지
Other_Faults는 두꺼울수록 많음	101~300에서 67.4%	151~300에서 72.4%	유지 (41~60에서만 17.3%로 낮음)
Z_Scratch·Stains는 중간 두께	둘 다 41~70	Stains 41~60 (71건), Z_Scratch 61~80 (170건)	유지 및 세분화
Bumps는 중간 두께	41~100에 약 72%	41~80에 약 61%	유지

- 목적: 두께에 따른 결함 유형 분포의 차이가 임의로 정한 구간 기준 때문에 나타난 것인지 확인하기 위함.

- 구간을 세분화하자 기존 41~70 구간에 함께 묶였던 Stains와 Z_Scratch가 분리됨. 두 결과를 함께 보면 Stains는 41~60, Z_Scratch는 61~70 구간에서 발생함.
- 변경 구간에서 Other_Faults가 41~60 구간에서만 낮은 것은, 이 구간을 Bumps(36.6%)와 Stains(35.1%)가 70% 이상 차지하기 때문임.
- 변경 구간에서 Pastry(23.9%)와 Dirtiness(12.9%)는 81~150 구간의 비율이 높게 나타남.
- 결론: 비율 수치는 일부 달라졌으나 주요 경향이 유지되어, 두께에 따른 차이는 구간 기준 때문에 나타난 결과가 아닌 것으로 판단됨.

6.8 강종과 두께의 관계

두께 구간	강종	Other_Faults	Bumps	K_Scatch	Z_Scratch	Pastry	Stains	Dirtiness	합계
40	A400	191	78	387	8	34	0	12	710
41~70	A300	104	141	0	170	23	0	8	446
41~70	A400	67	15	3	0	18	71	1	175
71~100	A300	104	120	1	2	20	1	0	248
71~100	A400	19	13	0	0	24	0	27	83
101~300	A300	58	18	0	0	6	0	1	83
101~300	A400	130	17	0	10	33	0	6	196

- 두께 40인 강판 710건은 모두 A400이며, A300은 모두 두께 41 이상임. 강종과 두께가 서로 얽혀 있음.

유형	같은 두께에서 강종 비교	결론
K_Scatch	두께 40에 A300이 없어 비교 불가. A400 안에서는 두께 40에 387건, 다른 두께는 3건 이하	두께 40과의 관련은 확인되나, 강종과 두께 중 어느 쪽과 관련된 것인지 분리할 수 없음
Z_Scratch	41~70: A300 170건, A400 0건	두께와 별개로 강종과 관련 있음
Stains	41~70: A300 0건, A400 71건	두께와 별개로 강종과 관련 있음
Dirtiness	71~100: A300 0건, A400 27건	두께와 별개로 강종과 관련 있음
Bumps	모든 구간에서 A300 비율이 더 높음 (71~100: 48.4% vs 15.7%)	강종과 관련 있음 (A300에 많음)
Pastry	모든 구간에서 A400 비율이 더 높음 (71~100: 8.1% vs 28.9%)	강종과 관련 있을 가능성 (건수가 적음)
Other_Faults	101~300: A300 69.9%, A400 66.3%	강종과 관계없이 두께와 관련됨

6.9 유형별 특성 종합

유형	크기	밝기	모양	강종	두께	위치	구분 난이도
K_Scatch	가장 큼 (6,281)	최소 밝기 가장 낮음 (41)	가로로 김, Edges_Y 낮음 (0.47)	A400 (391건 중 390건)	40 (391건 중 387건)	가장자리	쉬움
Stains	가장 작음 (16.5)	가장 밝음 (최소 115, 최대 140)	Edges_X 약 1	A400 (72건 중 71건)	41~60 (72건 중 71건)	판 안쪽	쉬움
Dirtiness	보통 (145)	밝은 편 (최소 107)	가장 길쭉함, 세로로 김	A400 (약 84%)	81~150 (55건 중 34건)	넓게 분포	보통 (55건)
Pastry	보통 (209)	평균 밝기 가장 어두움 (−0.18)	길쭉함, 세로로 김	차이 작음	81~150 (158건 중 63건)	넓게 분포	보통
Z_Scratch	보통 (146)	보통	약간 세로로 김	A300 (약 91%)	61~70 (190건 중 170건)	가장자리 근처	보통 (강종·두께 의존)
Bumps	보통 (120.5)	보통	정사각형에 가까움 (0.75)	A300 (약 69%)	41~80 (약 61%)	넓게 분포	어려움
Other_Faults	보통 (146)	보통	중간	차이 없음	두꺼울수록 많음 (151~300의 72.4%)	넓게 분포	가장 어려움

- 유형마다 구분에 도움이 되는 변수가 다름. 면적은 K_Scatch·Stains, 형상은 Dirtiness·Pastry, 강종·두께는 Z_Scratch를 구분함.
- Other_Faults·Bumps·Z_Scratch는 면적·밝기·형상이 겹쳐 강종·두께로만 일부 구분되므로, 모델에서 서로 혼동될 가능성이 높음.
- 위 관계는 함께 나타나는 관계이며 원인 관계로 해석할 수 없음.

7. 6단계: 독립변수 간 관계

7.1 분석 방법

- 대상: 수치형 입력 변수 25개 (글자로 된 fault_type과 정답 열은 제외).
- 피어슨 상관계수: 두 변수가 직선 관계로 함께 움직이는 정도.
- 스피어만 상관계수: 크고 작은 순서가 함께 움직이는 정도. 치우친 변수는 극단값 때문에 피어슨 값이 흔들릴 수 있어 함께 확인함.
- 상관계수는 −1~1이며, 절댓값 0.8 이상을 매우 강한 관계로 봄.

7.2 상관이 높은 변수 (피어슨 절댓값 0.8 이상, 15쌍)

묶음	변수 쌍 (상관계수)
위치	Y_Minimum-Y_Maximum (1.00), X_Minimum-X_Maximum (0.99)
크기	Pixels_Areas-Sum_of_Luminosity (0.98), Pixels_Areas-X_Perimeter (0.97), X_Perimeter-Sum_of_Luminosity (0.91), X_Perimeter-Y_Perimeter (0.91), Pixels_Areas-Y_Perimeter (0.83)
면적·축 변환값	LogOfAreas-Log_X_Index (0.89), LogOfAreas-Log_Y_Index (0.88), LogOfAreas-SigmoidOfAreas (0.88), Log_Y_Index-SigmoidOfAreas (0.84), Outside_X_Index-Log_X_Index (0.82)
방향	Outside_Global_Index-Orientation_Index (0.86)
밝기	Maximum_of_Luminosity-Luminosity_Index (0.87)
묶음 사이	Log_X_Index-Edges_Y_Index (−0.86)

- 15쌍에 수치형 25개 중 18개 변수가 포함됨.
- Y_Minimum·Y_Maximum은 다른 변수와 거의 관계가 없어, 세로 위치는 크기·밝기·모양과 독립적임.

7.3 유사 변수 비교

변수 쌍	피어슨	스피어만	의미
Pixels_Areas - LogOfAreas	0.65	1.00	순서는 완전히 같고 척도만 다른 같은 정보
Pixels_Areas - SigmoidOfAreas	0.42	0.98	같은 정보 (큰 면적이 1 근처로 눌려 순서 일부 손실)
LogOfAreas - SigmoidOfAreas	0.88	0.98	같은 정보
Pixels_Areas - Sum_of_Luminosity	0.98	0.99	사실상 같은 정보
Pixels_Areas - X_Perimeter	0.97	0.90	강한 관련
Pixels_Areas - Y_Perimeter	0.83	0.95	강한 관련
Y_Minimum - Y_Maximum	1.00	1.00	사실상 같은 정보
X_Minimum - X_Maximum	0.99	0.95	사실상 같은 정보
Outside_Global_Index - Orientation_Index	0.86	0.88	같은 방향 정보

- 면적과 그 변환값은 피어슨 상관이 낮게 나왔으나 스피어만 상관이 1에 가까워, 사실상 같은 크기 정보임. 따라서 크기 묶음과 면적·축 변환값 묶음은 하나의 크기 정보 묶음으로 볼 수 있음.

7.4 산점도

- Pixels_Areas-LogOfAreas: 면적이 커질수록 로그 면적도 항상 커지지만, 직선이 아닌 휘어진 곡선 관계임. 피어슨(0.65)이 낮고 스피어만(1.00)이 높은 이유를 보여 줌. 원래 면적에서 혼자 멀리 떨어진 최대 결함(152,655)이 로그 축에서는 5.18로 다른 값들과 가까워져, 로그 변환이 큰 값을 눌러 주는 효과도 확인됨.
- Pixels_Areas-Sum_of_Luminosity: 원점에서 시작하는 직선에 가까운 관계로, 밝기 합계가 면적에 비례해 커지는 값임을 보여 줌.
- Y_Minimum-Y_Maximum: 점들이 대각선 위에 일직선으로 놓여, 두 변수가 사실상 같은 값임을 보여 줌.

7.5 상관계수로 드러나지 않는 관계

행	Orientation_Index	Square_Index	1 − |Orientation_Index|	Outside_Global_Index
0	0.8182	0.1818	0.1818	1 (양수)
1936	−0.4286	0.5714	0.5714	0 (음수)
1940	−0.2000	0.8000	0.8000	0 (음수)

- 상관계수는 한 방향으로 함께 움직이는 관계만 측정하므로, 꺾인 모양의 관계는 놓칠 수 있음.

- Square_Index는 1 − |Orientation_Index|, Outside_Global_Index는 Orientation_Index의 부호(양수 1, 음수 0)와 일치함.
- 따라서 Orientation_Index 하나에 방향 관련 세 변수의 정보가 모두 담겨 있음. Square_Index는 상관계수는 낮지만 중복 정보에 해당함.
-

7.6 중복되지 않는 정보를 담은 변수 (6개)

- Edges_Index, Minimum_of_Luminosity, Empty_Index, Edges_X_Index, Steel_Plate_Thickness, Length_of_Conveyer
- 다른 입력 변수와 강한 상관(절댓값 0.8 이상)이 없고 다른 변수로 계산되지않아, 다른 변수로 대신할 수 없는 정보를 담고 있음(중간 정도의 상관은 있을 수 있음).
- 이 중 Edges_Index(K_Scatch), Minimum_of_Luminosity(K_Scatch, Stains), Edges_X_Index(Stains, Dirtiness), Steel_Plate_Thickness(K_Scatch, Z_Scratch, Stains, Other_Faults)는 결함 유형 구분에도 쓰여, 모델에서 빼면 대신할 변수가 없는 중요한 변수임.
-

7.7 특정 유형이 만든 관계

- 최소 밝기와 크기 변수의 반대 관계, Log_X_Index와 Edges_Y_Index의 강한 반대 관계(−0.86)는 크고 어두우며 가로로 길고 Edges_Y_Index가 낮은 K_Scatch에 의해 나타난 것으로 판단됨.

8. 주요 발견 사항 및 해석

1. **데이터 품질은 양호하나 유형별로 정렬되어 있음.**결측·중복·비정상값이 모두 없어 정제 부담이 적음. 다만 결함 유형별로 정렬되어 있어 분할 시 섞고 층화해야 함.
2. **클래스 불균형이 큼.**최다 유형(Other_Faults 673건)과 최소 유형(Dirtiness 55건)의 차이가 12.24배로, Macro F1 중심의 평가와 불균형 처리 비교가 필요하며 소수 유형 결과의 불확실성을 함께 제시해야 함.
3. **유형마다 구분에 도움이 되는 변수가 다름.**면적은 K_Scatch·Stains, 형상은 Dirtiness·Pastry, 강종·두께는 Z_Scratch를 구분함. 단일 변수로는 7개 유형을 모두 구분할 수 없어 여러 변수를 함께 사용하는 모델이 필요함.
4. **구분이 쉬운 유형과 어려운 유형이 뚜렷함.**K_Scatch와 Stains는 여러 변수에서 다른 유형과 겹치지 않아 구분이 쉬울 것으로 예상됨. 반면 Other_Faults·Bumps·Z_Scratch는 면적·밝기·형상이 겹쳐 서로 오분류될 가능성이 높으며, 이는 모델링 후 혼동행렬로 검증할 가설임.
5. **극단값은 오류가 아닌 유형 정보임.**크기 관련 변수의 극단값(최대 약 20%)은 주로 K_Scatch, 두께 극단값은 주로 Other_Faults에 해당하여 제거하지 않고 유지함.
6. **같은 정보를 담은 변수가 많고, 강종과 두께는 서로 얽혀 있음.**상관 0.8 이상인 15쌍과 방향 지표 3개의 계산 관계로 다수 변수가 중복 정보를 가짐. 또한 두께 40이 모두 A400이어서 K_Scatch의 관련 요인을 분리할 수 없음.

9. 전처리·모델링 반영 사항

순서	반영 사항	근거	적용 대상
1	입력 X는 feature_cols(27개), 정답 y는 fault_type으로 설정하고, 정답 7개 열과 fault_type은 X에서 제외함	정답 열이 X에 포함되면 데이터 누수가 발생함	모든 모델
2	강종을 팀 방식(A400 열 하나, 1 = A400, 0 = A300)으로 통일하여 입력 26개로 사용함	두 강종 열이 정반대로 같은 정보를 가짐	모든 모델 (팀 확정 후)
3	Train/Validation/Test를 섞어서 층화 분할하고, random_state를 고정해 모든 모델에 같은 분할을 사용함	유형별 정렬, 클래스 불균형	모든 모델
4	결측 처리는 생략하고 보고서에 사유를 기재함	결측 0건	–
5	극단값은 제거하지 않음	실제 큰 결함이며 특정 유형의 특징임	모든 모델
6	표준화를 적용하되, 기준은 Train 데이터로만 계산함	변수 간 숫자 범위 차이가 큼	로지스틱 회귀
7	치우친 변수의 로그 변환 효과를 비교함 (면적은 LogOfAreas 활용, 둘레·밝기 합계는 직접 변환 검토)	크기 관련 변수 왜도 5~39	로지스틱 회귀 (트리 계열은 불필요)
8	중복 변수의 유지·제외에 따른 성능을 비교함 (예: Y_Maximum, X_Maximum, Sum_of_Luminosity 제외, 방향은 Orientation_Index 하나만 사용)	상관 0.8 이상 15쌍, 방향 지표 계산 관계	주로 로지스틱 회귀 (심화 항목)
9	클래스 가중치(GBM은 sample_weight)와 샘플링(Random Under Sampling, SMOTE 계열)을 비교하며, 샘플링은 Train에만 적용하고 SMOTE 계열은 강종을 범주형으로 지정함	불균형 비율 12.24배	비교 실험
10	Macro F1을 주지표로 하고, 유형별 Precision·Recall·F1과 혼동행렬을 함께 확인함	불균형, Other_Faults·Bumps·Z_Scratch 혼동 예상	모든 모델
11	(선택) 파생변수 밝기 차이(최대 밝기 − 최소 밝기), 두께 구간의 효과를 비교함	K_Scatch의 큰 명암 차이, 중간 두께에 몰린 유형 존재	심화 실험 (주로 로지스틱 회귀)

10. 해석시 주의사항

- 변수와 결함 유형의 관계는 함께 나타나는 관계이며 원인 관계로 해석할 수 없음. 특히 강종과 두께는 서로 얽혀 있어, K_Scatch는 ‘A400·두께 40 강판에서 주로 나타남'으로만 기술함.
- Dirtiness(55건)와 Stains(72건)는 표본이 적어, 유형별 비교와 성능 결과의 불확실성이 큼.
- 중앙값은 대표값만 나타내므로 구분 가능성은 박스플롯의 겹침과 함께 판단함.
- 그래프에서 읽은 값은 '약'으로 표기한 근사값이며, 정확한 값은 표의 수치를 기준으로 함.
- 두께 구간은 분석을 위해 정한 기준이나, 구간을 변경해도 주요 경향이 유지됨을 확인함.